


다이아몬드 가격 예측

감정서에 적힌 정보(무게·컷·색·투명도·크기)만 보고
다이아몬드 가격을 맞추는 모델을 만든 과정

표 데이터 회귀

평가 지표 RMSLE

학습 40,000개 · 예측 13,940개



문제: 감정서 정보로 가격을 맞혀라

입력 열 9개를 보고 가격(USD) 하나를 예측합니다

입력

캐럿(무게)

컷

색상

투명도

x·y·z 크기

깊이(depth)

테이블



출력

가격 (USD)

평가 지표 RMSLE = “비율로 얼마나 틀렸나”

정답 \$1,000 → 예측 \$1,100 (10% 틀림)

정답 \$10,000 → 예측 \$11,000 (10% 틀림)

두 경우를 같은 크기의 오류로 봅니다.

값이 작을수록 좋은 점수입니다.

0.3938

이 점수 이상이면 0점
(제공된 간단한 선형회귀 기준)

40,000개

학습 데이터 (가격 포함)

13,940개


가격을 맞혀야 하는 데이터

90분

3문제 전체 제한 시간

전체 작업 흐름

5단계로 나누어 하나씩 점수를 확인하며 진행했습니다



점수(RMSLE)는 낮을수록 좋습니다. 각 단계마다 **같은 5-Fold 교차검증**으로 비교해서, 좋아진 것만 채택했습니다.


교차검증이란? 학습 데이터를 5조각으로 나누어, 4조각으로 학습하고 나머지 1조각으로 시험보기를 5번 반복해 평균 점수를 내는 방법입니다. 정답을 모르는 test 점수를 미리 짐작하는 용도입니다.

핵심: 한 번에 하나만 바꾸고, 같은 기준(5-Fold)으로 점수를 비교한다


데이터 살펴보기: 가격은 한쪽으로 쏠려 있다

싼 다이아몬드는 많고, 비싼 것은 드뭅니다

그대로 보면: 오른쪽으로 길게 늘어짐



로그를 취하면: 균형 잡힘




- 가격이 **\$300 ~ \$18,000** 이상까지 넓게 퍼져 있습니다.
- RMSLE는 **비율 오차**를 보니, 가격에 **로그**를 취해서 학습하면 지표와 딱 맞습니다.

로그를 취하면 "2배 비싸다"가 같은 간격이 되어, 모델이 싼 것과 비싼 것을 공평하게 배웁니다.

핵심: 가격은 로그로 보면 균형이 잡힌다 → 로그 가격으로 학습한다

데이터 정리: 같은 값이 다르게 적혀 있었다

사람이 입력한 듯한 표기 오류와 측정 오류를 바로잡았습니다



표기 오류

컷: **ideal** / Ideal, 투명도: **VS2**_(끝에 공백)

결측

depth·table 약 3%가 비어 있음

측정 오류

x·y·z가 0 (22건), y=58.9 같은 이상치

복원 공식


$\text{depth} = 100 \times z \div \text{평균}(x, y)$

빠진 값을 이 관계로 계산해 채움

핵심: 모델을 고르기 전에 데이터부터 바로잡는다

모델: 질문을 이어가는 나무 + 여러 나무의 평균

“나무 모델”은 예/아니오 질문을 이어가며 가격을 좁혀 갑니다



앙상블 = 여러 모델의 평균




- 한 모델의 실수를 다른 모델이 보완해 줍니다.
- 타깃 변환: 가격 대신 로그 가격을 맞히고, 캐럿 때문에 생기는 큰 추세는 먼저 빼 두었다가 나중에 더합니다.

핵심: 서로 다른 모델 여러 개를 평균하면 한 모델의 실수가 줄어든다

개선 과정: 기준 대비 오차가 약 1/5로

단계마다 점수를 확인하며 쌓아 올렸습니다 (CV RMSLE, 낮을수록 좋음)



0.3938 → 0.0810

제공 기준 대비 오차가 약 1/5

파생 특징



가장 큰 개선(0.0895 → 0.0851): 부피·로그 캐럿 등 새 열 만들기

CatBoost는 범주(컷·색상)를 잘 다루는 모델이라 한 단계 더 좋아졌습니다.

핵심: 데이터 정리 → 새 특징 → 더 좋은 모델 순서로 오차가 줄었다

더 줄이기 어려웠던 이유: 소수의 행이 오차를 지배

오차 분석(OOF 예측 기준): 행 1%가 전체 오차의 21%를 차지합니다



해석 주황색 점은 같은 조건처럼 보이는데 가격이 크게 다른 다이아몬드입니다. 이런 **라벨 노이즈**는 모델을 바꿔도 줄이기 어려워, 개선의 한계가 되었습니다.

최종 결과와 배운 점

제출 파일 검증까지 마친 최종 버전(v3)

0.0810

교차검증 RMSLE (추정)

약 79.4점

환산 점수 (추정)

$100 \times (1 - 0.0810 / 0.3938)$

13,940행

제출 파일 형식·id 검증 통과

배운 점

- 모델보다 **데이터 정리**가 먼저입니다.
- 평가 지표가 비율 오차면 **로그 타깃**이 맞습니다.
- 오류 분석을 먼저 하면 **개선 한계**를 알 수 있습니다.

주의 점수는 test 채점이 아닌 교차검증 추정치입니다.

CatBoost는 문제의 허용 목록에 이름이 없습니다. 대회 환경에서 쓸 수 없을 때를 대비해 **sklearn만 쓰는 대체 버전**(CV 0.0831)도 보존했습니다.