


영화 리뷰 감성 분류

짧은 한 줄 리뷰가 긍정인지 부정인지
자동으로 맞추는 모델을 만든 과정

한국어 텍스트 이진 분류

평가 지표 정확도

학습 20,000개 · 예측 10,000개



문제: 리뷰 한 줄 → 긍정 / 부정

맞춤법 오류, 초성(ㅋㅋ·ㅠㅠ), 띄어쓰기 생략이 많은 실제 리뷰입니다

정말 잘만든 한 인간의 일대기

긍정

연출, 기획, 스토리 전부다 쓰레기..

부정

알바가 있긴 있군요

부정

20,000개

학습 리뷰 (정답 포함)

10,000개

맞혀야 하는 리뷰

1 : 1

긍정 10,032 · 부정 9,968


정확도

맞힌 비율로 평가 (높을수록
 좋음)

“알바가 있긴 있군요”처럼 사람도 헛갈리는 문장이 있어서, 100%는 불가능한 문제입니다.

전체 작업 흐름

쉬운 방법부터 시작해서, 하나씩 시도하고 점수로 비교했습니다




정확도는 5-Fold 교차검증으로 했습니다. 결론부터 말하면, **간단한 방법(글자 조각 + 나이브 베이즈)**이 가장 강했고 복잡한 시도는 이득이 거의 없었습니다.

핵심: 단순한 방법이 가장 강했고, 복잡한 시도는 이득이 거의 없었다

데이터 살펴보기

리뷰는 짧고(평균 36자), 말투가 제각각입니다



이런 표현이 많습니다

ㅋㅋㅋㅋ

ㅠㅠ

^^

절대보지마요진심 (띄어쓰기 없음)

잼업다 (오타)

재밌어요 (표기 변형)

결측값·중복 리뷰는 없고, train과 test의 길이 분포도 비슷했습니다. 그래서 **말투(표현)** 문제를 어떻게 다루느냐가 핵심입니다.

핵심: 표현이 제각각이라 단어보다 “글자 조각”이 안전하다

글을 숫자로: 글자 조각(n-gram)

단어로 자르지 않고, 1~4글자 조각의 등장 횟수를 셉니다

리뷰

노잼ππ

↓ 잘게 썰기

노 잼 π 노잼 잼π ππ 노잼π
잼ππ ...

띄어쓰기가 없거나 오타가 있어도, 일부 조각은 그대로 남아 단서가 됩니다.

“조각이 어느 쪽에 더 자주 나오나?” 세기

긍정 신호

잼나

굿굿

짱!

♡♡

잊을

부정 신호

최악

아깝다

노잼

1점도


유치하고

※ 학습 데이터에서 자동으로 뽑은 표현 예시

핵심: 오타·띄어쓰기가 틀려도 글자 조각 일부는 남아 단서가 된다

모델 비교: 가장 단순한 모델이 강했다

나이브 베이즈(NB)는 조각별 "긍정/부정 편향"을 곱해 판단하는 가벼운 모델입니다



- **NB 계열**이 로지스틱 회귀·SVM·RNN보다 높았습니다.
- RNN(글자 단위 GRU)은 데이터가 2만 개로 적어 오히려 낮았습니다.

순위 평균


모델마다 점수 크기가 달라서, 점수 대신 "몇 번째로 긍정 같은가" 순위를 평균 냈습니다. 확률을 그냥 평균하면 0.8386으로 오히려 떨어졌습니다.

핵심: 복잡한 모델보다 가벼운 나이브 베이즈 + 순위 평균이 가장 안정적이었다

오류 분석: 모델이 불확실할 때 틀린다

틀린 문장의 대부분은 사람도 판단이 어려운 문장입니다

구간별 오답 비율



모델이 확신했는데 틀린 문장

가슴 따뜻해지는 명작..

정답 부정

재밌어요 ^^ 추천 나만죽을수없다.

정답 부정


내용만 보면 긍정인데 정답이 부정이거나, 반어·비꼼인 경우입니다. 이런 **라벨 노이즈**는 모델이 고칠 수 없는 한계입니다.

역접("~지만", "근데") 문장은 오류율 17.4%로 평균(15.2%)보다 높았습니다.

핵심: 틀린 문장은 사람도 헷갈리는 문장 — 라벨 노이즈가 한계를 만든다

개선 시도 결과: 대부분 오차 범위 안

막대가 회색 띠(노이즈 범위) 안이면 "진짜 개선인지 알 수 없다"는 뜻입니다



- 전처리(슬랭·이모티콘 바꾸기)는 오히려 손해: 글자 조각이 이미 그 표현을 배우고 있었기 때문.
- RNN 추가·세부 조정은 +0.2%p 안팎으로 **노이즈 수준**.
- 최종은 표현 특징(24개)을 더한 v2 입니다.

핵심: 이득이 노이즈 범위 안이면 더 단순한 쪽을 고른다

최종 결과와 배운 점

제출 파일 검증까지 마친 최종 버전(v2)

0.8487

교차검증 정확도 (추정)

약 84.9점

환산 점수 (추정, 100×정확도)

10,000행

제출 파일 형식.id 검증 통과

배운 점

- 단순한 모델부터 시작해 **한 번에 하나씩** 바꿔 보기.
- 이득이 **노이즈 안**이면 복잡한 쪽을 고르지 않기.
- 모델이 틀리는 이유(라벨 노이즈)를 먼저 이해하기.

다음 단계(미실행)

한국어 사전학습 모델의 문장 임베딩이 가장 큰 개선 후보입니다.
속도 측정에서 3만 문장에 약 13분으로 추정되어 중단했습니다.
점수는 test 채점이 아닌 교차검증 추정치입니다.