

3문제 풀이 한눈에 보기

part1 (26_10_08): 정형 회귀 · 시계열 예측 · 이미지(숫자 합) | 모든 점수는 검증(CV·백테스트·홀드아웃) 추정치이며 test 점수가 아닙니다

P1 뉴욕 택시 팁 예측

정형 회귀 · 지표 MAE (낮을수록 좋음)
데이터: train 4,500 / test 1,933

[알고리즘] 2단계 CatBoost

- 1) 결제수단 규칙: 현금·결측 → 팁 0
- 2) 카드 행: 팁=0 분류기(p0)
 $p0 > 0.5 \rightarrow 0$ 예측
- 3) 그 외: 팁률(tip/fare) 회귀 × fare

[데이터 처리]

시각 → 시·요일·운행시간, 비율 파생
0 거리·0 승객은 결측으로 처리
범주 결측 = "_MISSING_"

[트리] CatBoost 대칭(oblivious) 트리

250그루 × 깊이 6/7

[검증] 3-Fold OOF MAE

평균 팁 1.627 → 규칙 0.891
→ 팁률 CatBoost 0.582
→ 2단계 0.5505

P2 가정 일일 전력 사용량

시계열 예측(90일) · 지표 MAE
데이터: 1,351일(2006-12~2010-08)

[알고리즘] 구간별 결합 앙상블

프로필·HGB·RF·푸리에 선형 평균(v2)
+ 프로필·RF 평균(E7)
8/31 E7 → 9/30 v2 로 선형 전환

[데이터 처리]

이상 구간(2008-08-06~30) 학습 제외
과거 3년 같은 날짜 ±7일 평균의 중앙값
× 요일 배수 = 계절 프로필
날짜 특징만 사용(외생 변수 없음)

[트리] RandomForest 200그루

HistGradientBoosting 200회

[검증] 시간 순서 백테스트(10구간)

제공 베이스라인 11.44 → 4.39

P3 두 손글씨 숫자의 합

이미지 19분류(합 0~18) · 지표 정확도
데이터: 쌍 10,000(합만) + 숫자 1,000

[알고리즘] 합 라벨 약지도 CNN

쌍 이미지를 반으로 잘라 숫자 CNN 공유
pL, pR → 합성곱 → 합 확률
합 라벨로 학습 + 숫자 라벨 손실 병행

[데이터 처리]

28×56 → 왼쪽/오른쪽 28×28
±2픽셀 이동 증강, 표준화

[트리] 사용하지 않음

(CNN 3블록, 합 확률은 확률 계산)

[검증] 홀드아웃 2,000쌍 정확도


숫자만 학습 0.9720
→ 합 라벨 약지도 0.9860

공통 원칙: 시간 순서/그룹을 지키는 검증(누수 방지) · 정답 라벨로 학습 데이터만 사용 · 최종 선택은 같은 분할의 비교 + 노이즈(부트스트랩) 확인




P1 · 데이터 처리: 택시 운행 기록 → 모델 입력

결제수단 규칙이 가장 큰 단서: 현금·결제수단 결측 1,308건은 train 에서 팁이 모두 0

처리 순서




※ 검증 시 전처리·모델은 각 fold 의 학습 부분에서만 적합(누수 방지). 팁률 규칙도 학습 데이터에서 확인된 사실만 사용




P1 · 알고리즘: 팁 0 분류 + 조건부 회귀 (2단계 CatBoost)

지표가 MAE 라서: 0 확률이 절반 이상이면 중앙값 = 0, 아니면 $\text{tip} > 0$ 의 조건부 중앙값을 예측
추론 흐름



버전별 MAE (앞 두 개는 train 전체, 나머지는 3-Fold OOF)



왜 2단계인가

- 카드 행 3,192건 중 팁 0 이 330건(10.3%)이고 이전 메인(팁률 CatBoost)은 이 중 41건만 잡았음
- 이 330건이 전체 오차의 25.4% 를 차지
- 팁 0 은 green 택시 48.7%, Bronx/Brooklyn 승차 93%/54% 등으로 예측 가능(AUC 0.872)

임계값 0.5 의 근거

- MAE 를 최소화하는 예측은 중앙값
- $\text{tip}=0$ 확률이 0.5 이상이면 중앙값이 0
- 스윙(0.3~0.7)에서도 0.5 가 최저 (0.5505, 0.4: 0.5534, 0.6: 0.5612)
- 튜닝한 값이 아니라 이론 기준


검증 결과

- 같은 3-Fold OOF: 0.5816 → 0.5505
- 차이 -0.0312, 95% 구간 [-0.047, -0.015] (0 미포함, 세 fold 모두 개선)
- 0 으로 예측한 카드 209건 중 179건 적중
- 잘못 0 으로 예측한 $\text{tip} > 0$ 행 30건


P1 · 트리 구조: 팀 0 을 가르는 규칙

왼쪽: 해석용 결정 트리(깊이 3) | 오른쪽: 실제 CatBoost 분류기의 첫 번째 대칭(oblivious) 트리 (250그루 중 1번)

결정 트리 (신용카드 행 3,192건, 팀=0 여부) - 해석용 간단한 모델



CatBoost 대칭 트리: 같은 깊이는 같은 조건 (깊이 6, 잎 64개)



읽는 법
· 라벨: 조건이 맞으면 "예"
· 오른쪽 상자 = 깊이 4 이후
3단계 더 분기한 잎 8개의
합산 요약
· 기여 = 이 트리가 더하는
로그오즈 (빨강: 팀=0 쪽,
초록: 팀>0 쪽)

노트: samples=행 수, value=[팀>0, 팀=0]. 주황=팀>0 다수, 파랑=팀=0 다수(진할수록 순수). 5-Fold AUC 0.825 (실제 CatBoost 분류기 0.871).

깊이 4~6 조건: 깊이 4: 통행료/마일 > 0.57 ? | 깊이 5: 승차 자치구 팀0 통계(CTR) > 구간 9 ? | 깊이 6: 하차 자치구 팀0 통계(CTR) > 구간 3 ?

CatBoost 는 범주형(자치구)을 "그 범주의 팀 0 비율(타깃 통계, CTR)" 구간으로 바꿔 분할합니다. 대칭 트리는 한 깊이의 모든 노드가 같은 조건을 쓰는 구조라 과적합에 강하고 예측이 빠릅니다.

이런 트리 250그루를 더해(부스팅) 최종 팀=0 확률 p0 를 만들며, 회귀기(깊이 7)도 같은 구조입니다.

P1 · 수학적 구조: 2단계 CatBoost

그래디언트 부스팅 + 대칭 트리 + 범주형 타겟 통계(CTR) + 중앙값 최적 결정 규칙

① 전체 예측식

$$\hat{y} = \mathbf{1}[\text{card}] \cdot \mathbf{1}[p_0(x) \leq 0.5] \cdot \text{fare} \cdot \hat{r}(x)$$

현금·결측 결제는 팁 0. 카드 행은 $p_0(\text{팁}=0 \text{ 확률})$ 과 팁률 $r(\text{tip}/\text{fare})$ 회귀값으로 결정 ($p_0 > 0.5$ 이면 0)

② 부스팅 모델 (분류기·회귀기 공통)

$$F_M(x) = F_0 + \eta \sum_{m=1}^M f_m(x), \quad f_m(x) = w_{\text{idx}(x)}^{(m)}$$

$$\text{idx}(x) = \sum_{d=1}^D 2^{d-1} \mathbf{1}[x_{j_d} > t_d] \quad (2^D \text{ leaves})$$

대칭(oblivious) 트리: 깊이 d 의 모든 노드가 같은 (변수 j_d , 임계값 t_d) 사용 → 앞 2^d 개. 분류기 $D=6$, 회귀기 $D=7$, $M=250$

③ 분류기: 로지스틱 손실

$$p_0 = \sigma(F(x)) = \frac{1}{1 + e^{-F(x)}}, \quad \mathcal{L} = -\sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

$$g_i = p_i - y_i, \quad h_i = p_i(1 - p_i), \quad w_\ell = -\frac{\sum_{i \in \ell} g_i}{\sum_{i \in \ell} h_i + \lambda}$$

기울기 g , 헤시안 h 로 뉴턴 한 걸음: 앞 값 w 계산. 분할은 손실 감소가 가장 큰 (변수, 임계값) 한 쌍을 깊이마다 선택

④ 회귀기: 가중 MAE 손실

$$\hat{r} = \arg \min_F \sum_i \text{fare}_i |r_i - F(x_i)|, \quad r_i = \text{tip}_i / \text{fare}_i$$


$$\text{fare}_i |r_i - F| = |\text{tip}_i - \text{fare}_i F| \rightarrow \text{팁(달러) MAE 를 그대로 최소화}$$

⑤ 범주형: 순서형 타겟 통계(CTR)


$$\text{CTR}_i = \frac{\sum_{j < i, c_j = c_i} y_j + aP}{\#\{j < i, c_j = c_i\} + a}$$

무작위 순서에서 앞선 행만 사용(자기 라벨 누수 방지). P =사전확률, a =가중. 자치구 같은 범주를 이 값으로 바꿔 분할

MAE 의 최적 예측은 중앙값



시그모이드: 점수 → 확률



P1 · Stage-by-stage: two-stage CatBoost, outputs, loss

Taxi tip regression | metric: MAE | train 4,500 rows, test 1,933 rows

Stage	Operation / setting	Output
Input	raw columns: fare, distance, time, boroughs, color, passengers, tolls, payment	row
Preprocess	hour / weekday / duration / speed; zero distance → missing; cat. NaN → "_MISSING_"	features x
Rule	payment is cash or missing → tip = 0 (no model)	y = 0
Classifier	CatBoostClassifier: 250 trees, depth 6, lr 0.06, oblivious trees, CTR on categoricals	F(x)
Link	sigmoid: $p_0 = 1 / (1 + \exp(-F))$	p0 in (0,1)
Decision	$p_0 > 0.5 \rightarrow \text{tip} = 0$	zero / non-zero
Regressor	CatBoostRegressor: 250 trees, depth 7, lr 0.06, l2 5; tip>0 card rows, weight = fare	F(x)
Link	identity: $r_hat = F(x)$ (rate = tip / fare)	r_hat
Output	tip_hat = fare * r_hat	dollars

Output transforms

$$\sigma(F) = \frac{1}{1 + e^{-F}} \quad (\text{classifier})$$

$$\hat{r} = F(x) \quad (\text{regressor, identity})$$

Loss

$$\mathcal{L}_{\text{cls}} = -\sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$


$$\mathcal{L}_{\text{reg}} = \sum_i \text{fare}_i |r_i - F(x_i)|$$

$$= \sum_i |\text{tip}_i - \text{fare}_i F(x_i)|$$

Boosting update

$$F_m = F_{m-1} + \eta f_m, \quad f_m(x) = w_{\text{idx}(x)}$$

$$w_\ell = -\frac{\sum g_i}{\sum h_i + \lambda}$$



3-Fold OOF MAE 0.5505
(prior 0.5816, single CatBoost 0.5959,
ExtraTrees 0.6387, mean-tip 1.6265)
zero-tip classifier AUC 0.872

P1 · 사용된 구성 요소 설명

앞 페이지 표의 각 단계가 무엇을 하는지 간략 설명

CatBoost (gradient boosting)

얇은 트리를 순서대로 추가하며, 직전까지의 오차(기울기)를 줄이는 방향으로 다음 트리를 학습. 최종 점수 $F(x) = \text{초기값} + \eta \cdot \sum \text{각 트리 출력}$.

Oblivious (symmetric) tree

같은 깊이의 모든 노드가 같은 분할 조건을 사용 $\rightarrow$ 깊이 D 이면 잎 2^D 개. 구조가 단순해 과적합에 강하고 예측이 빠름 (분류기 $D=6$, 회귀기 $D=7$).

Ordered CTR (범주형 처리)

자치구·색 같은 범주를 "그 범주의 타깃 평균(사전값 보정)"으로 바꿔 분할. 무작위 순서에서 앞선 행만 사용하므로 자기 라벨 누수가 없음.

Logloss + sigmoid (분류기)

팁=0 확률 $p_0 = \sigma(F)$. 손실은 $-[y \log p + (1-y) \log(1-p)]$. 기울기 $p-y$, 헤시안 $p(1-p)$ 로 잎 값을 뉴턴 방식으로 계산.

Weighted MAE (회귀기)

타깃은 팁률 $\text{rate} = \text{tip}/\text{fare}$, 가중치 = fare.
 $\sum \text{fare} \cdot |\text{rate} - F| = \sum |\text{tip} - \text{fare} \cdot F|$ 이므로 달러 단위 MAE 와 같은 목적.


Rule + threshold (결정 규칙)

현금·결측 결제는 모델 없이 0. 카드 행은 $p_0 > 0.5$ 이면 0.
MAE 의 최적 예측은 중앙값이라, $P(\text{팁}=0) > 0.5$ 이면 0 이 최적.


P2 · 데이터 처리: 전력 사용량 시계열 → 계절 프로파일 + 날짜 특징

날짜 외 정보가 없는 순수 시계열 · 학습 1,351일 → 예측 2010-08-29 ~ 11-26 (90일)


일일 전력 사용량: 겨울에 높고 여름에 낮음, 2008년 8월에는 장기 부재로 보이는 4~5 kWh의 평탄 구간



월 평균(kWh): 계절성은 연도마다 비슷
(8월 2008 만 예외)



요일 배수 (값 / 7일 이동평균)
토·일이 평일보다 약 10~15% 높음



① 이상 구간 제거: 2008-08-06~30 → 결측

② 프로파일: 과거 연도 같은 월·일 ±7일 평균의 연도 중앙값 (예측 연도 이전만 사용)

③ × 요일 배수 (전체 연도)


④ 날짜 특징: 추세 t , 공휴일, 요일·월·연중일
푸리에 $\sin/\cos$ 1~2차 (선형은 3차 + 요일 더미)

⑤ 검증: 과거 연도(2008-2009)의 같은 90일을 시간 순서로 예측하는 10구간 백테스트


P2 · 알고리즘: 구간별 결합 앙상블 (v3)

8월 말~9월 초에는 9월 저평가가 적은 E7(프로필+RF)을, 이후에는 4모델 평균(v2)을 쓰도록 30일에 걸쳐 선형 전환


예측 흐름



예측 구간의 E7 가중치



예측 vs 과거 3년 같은 시기





9월에 v2 는 과거(약 23.5)보다 낮고(21.9), E7 은 과거와 일치(23.8).
전환 구간에서 두 모델을 섞어 9월 저평가를 줄였습니다.

P2 · 트리 구조: RandomForest 와 모델 비교

RF 200그루 중 첫 번째 트리의 윗부분(깊이 3)과 변수 중요도 | 아래: 백테스트 MAE 비교


RF 첫 번째 트리 (총 깊이 14, 잎 134개 중 윗부분 깊이 3만 표시)



연중 주기(cos 1차)와 추세, 요일이 중요. 단, 트리는 외삽을 못해서 8월 말~9월 초의 급한 반등 같은 구간 경계에 약함.

노드: 분할 조건(참이면 왼쪽), samples=학습 일수, value=그 노드의 평균 kWh. 색이 진할수록 평균이 큼. 같은 방식의 트리 200그루를 평균해 예측합니다.

시간 순서 백테스트 MAE (10구간 평균, 낮을수록 좋음)



시도했으나 채택하지 않은 것

- 수준 보정(최근 YoY 곱하기): 연초 YoY 가 가을로 이어지지 않음
- 1D CNN(프로필 잔차): 단독 4.84, 앙상블 이득 없음
- 프로필을 입력 특징으로 준 트리: 편향이 커짐
- 가중치 학습/중량값 결합: 연도 간 일반화 안 됨

P2 · 수학적 구조: 프로필 + 트리·선형 앙상블

계절 프로필, 푸리에 선형회귀(OLS), RandomForest(분산 감소), HGB(MAE 부스팅), 구간별 결합

① 계절 프로필 × 요일 배수

$$\bar{s}_y(d) = \frac{1}{15} \sum_{k=-7}^7 s_y(d+k), \quad P(d) = \text{median}_{y < Y} \bar{s}_y(d)$$

$$f_j = \text{mean} \left\{ \frac{s_t}{\text{MA}_7(s_t)} : \text{dow}(t) = j \right\}, \quad \hat{s}_{\text{prof}}(d) = P(d) f_{\text{dow}(d)}$$

② 푸리에 선형회귀 (OLS)

$$s_t = \beta_0 + \beta_1 t + \sum_{k=1}^3 \left[a_k \sin \frac{2\pi k \text{doy}}{365.25} + b_k \cos \frac{2\pi k \text{doy}}{365.25} \right] + \gamma_{\text{dow}} + \varepsilon$$

$$\hat{\beta} = (X^\top X)^{-1} X^\top s$$

③ RandomForest (B=200)

$$\hat{s}_{\text{RF}}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (T_b: \text{부트스트랩 표본으로 학습한 회귀 트리})$$

$$\min_{j, \tau} \left[\sum_{i \in L} (s_i - \bar{s}_L)^2 + \sum_{i \in R} (s_i - \bar{s}_R)^2 \right], \quad \text{leaf} = \bar{s}, \quad n_{\text{leaf}} \geq 5$$

평균의 분산 = $\rho \sigma^2 + (1-\rho) \sigma^2 / B$ (ρ : 트리 간 상관, σ^2 : 트리 1개의 분산) → 트리를 늘려 분산 감소. 변수 중요도 = 분할 손실 감소량의 합(정규화)

④ HistGradientBoosting (절대오차 손실)

$$F_m = F_{m-1} + \nu h_m, \quad h_m \approx \text{sign}(s - F_{m-1}), \quad \mathcal{L} = \sum_i |s_i - F(x_i)|$$

특징을 255 구간 히스토그램으로 이산화해 빠르게 분할. 200 회 반복, 잎 15개

⑤ 앙상블과 구간별 전환

$$v_2 = \frac{1}{4}(\text{prof} + \text{HGB} + \text{RF} + \text{lin}), \quad E_7 = \frac{1}{2}(\text{prof} + \text{RF})$$

$$\hat{s}(d) = w(d) E_7(d) + (1 - w(d)) v_2(d), \quad w(d) = \text{clip} \left(1 - \frac{d - \text{Aug } 31}{30}, 0, 1 \right)$$

⑥ 평가

$$\text{MAE} = \frac{1}{n} \sum_t |s_t - \hat{s}_t|, \quad \text{시간 순서 백테스트(과거 연도 같은 90일 × 여러 시점)의 평균}$$

P2 · Stage-by-stage: profile + tree/linear ensemble, outputs, loss

Daily electricity (kWh) forecast, 90 days | metric: MAE

Stage	Operation / setting	Output
Input	daily kWh 2006-12 ~ 2010-08 (1,351 days), date only	series s _t
Clean	mask 2008-08-06~30 (anomaly) → NaN, exclude from fit	fit set
Features	t, holiday, dow, month, doy, sin/cos(2*pi*k*doy/365.25), k=1,2 (linear: k=1..3 + dow dummies)	x _t
Profile	median over past years of centered 15-day mean at same month-day, times dow factor	prof
HGB	HistGradientBoosting: absolute_error, 200 iter, lr 0.05, 15 leaves, min leaf 15	hgb
RandomForest	200 trees, min_samples_leaf 5, squared-error splits, mean of trees	rf
Linear	OLS: trend + Fourier(3) + dow dummies	lin
Blend A	v2 = (prof + hgb + rf + lin) / 4; E7 = (prof + rf) / 2	v2, E7
Blend B	w(d) = clip(1 - (d - Aug 31)/30, 0, 1); s_hat = w*E7 + (1-w)*v2	s_hat(d)

Output transforms

identity (all four models are regressors)

w(d): linear ramp 1 → 0 over Aug 31 ~ Sep 30

Loss

HGB: $\sum_i |s_i - F(x_i)|$ (absolute error)

RF split: $\sum_L (s - \bar{s}_L)^2 + \sum_R (s - \bar{s}_R)^2$

OLS: $\hat{\beta} = (X^T X)^{-1} X^T s$

profile: no loss (median)

Evaluation

MAE = $\frac{1}{n} \sum_t |s_t - \hat{s}_t|$



Final = v3 (ramp blend)
Backtest MAE 4.386
(provided 7-day baseline 11.443)

Backtest MAE (10 windows): prof 4.561, RF 4.631, HGB 4.724, lin 4.765, v2 4.404, E7 4.478, v3 4.386

P2 · 사용된 구성 요소 설명

앞 페이지 표의 각 단계가 무엇을 하는지 간략 설명

Seasonal profile

과거 연도의 같은 월·일 ± 7 일 평균을 구해 연도 간 중앙값을 취함 (계절 수준).
여기에 요일 배수(값 / 7일 이동평균의 요일별 평균)를 곱함. 학습 없는 기준 모델.

Fourier features

$\sin/\cos(2\pi \cdot k \cdot \text{doy}/365.25)$ 로 연중 주기를 부드러운 곡선으로 표현.
 k 가 클수록 빠른 변동 (트리·HGB 는 $k=1\sim 2$, 선형은 $k=1\sim 3$).

Linear regression (OLS)

trend + Fourier + 요일 더미의 선형 결합. $\beta = (X^T X)^{-1} X^T s$.
단순하고 외삽이 가능하지만 급한 계절 전환에는 약함.

RandomForest

부트스트랩 표본마다 깊은 회귀 트리를 학습해 평균 (200그루, 최소 잎 5).
분할은 분산 감소 기준. 트리 간 평균으로 분산을 줄이며 외삽은 못함.

HistGradientBoosting

특징을 구간(히스토그램)으로 나눠 빠르게 부스팅.
절대오차(absolute_error) 손실이라 이상치에 덜 민감 (200회, lr 0.05, 잎 15개).


Ensemble + ramp

$v2$ = 프로필·HGB·RF·선형 평균, $E7$ = 프로필·RF 평균 (서로 다른 오차를 상쇄).
8/31 $\rightarrow$ 9/30 에 걸쳐 $E7$ 가중치를 $1 \rightarrow 0$ 으로 줄여 구간별로 결합 ($v3$).




P3 · 알고리즘: 합 라벨만으로 숫자 분류기 학습 (약지도 CNN)

손글씨 두 숫자 이미지(28x56)와 그 합만 주어짐 · 개별 숫자 라벨은 1,000장뿐 · 트리 없음(CNN)

추론/학습 흐름



실제 모델이 검증 쌍 1개에서 낸 출력 (모델: 학습에 쓰지 않은 2,000쌍 홀드아웃에서 0.986)




손실
· 합: $-\log q(\text{정답 합})$
· 숫자: 라벨 1,000장
교차엔트로피
(라벨 스무딩 0.05)
· 둘을 더해 학습

학습: AdamW + OneCycle, 20 에폭, ± 2 픽셀 이동 증강, CPU. 합 라벨에서 숫자 분류기가 스스로 만들어지는 것이 핵심(합 5 = 2+3, 1+4, ... 의 제약이 겹치며 정답으로 수렴).


P3 · 데이터 처리와 결과

데이터 점검 → 학습 구성 → 방법 비교 → 남은 오류


합 라벨 분포 (train 10,000쌍)



데이터 처리 4단계 (누수 점검: 쌍·digits 픽셀 동일 0건, 밝기·획 두께 분포 동일)



홀드아웃 합 정확도 (2,000쌍)



시드 3개 모두 틀린 검증 쌍(18개) 일부



결과 요약

- 약지도(B)가 A 보다 +1.4%p (표준오차 약 0.26%p)
- 시드 앙상블: 개선은 노이즈 수준 → 1시드 유지
- 남은 오류: 필기가 모호하거나 비정형인 숫자 (가운데 그림, 시드 3개 모두 오답)
- 제출: 전체 10,000쌍으로 학습, 4,000행 (정확도는 홀드아웃 추정치이며 test 점수 아님)
- 트리 없음: 이미지는 CNN 이 적합

P3 · 수학적 구조: 합 라벨 약지도 CNN

공유 CNN 의 소프트맥스 + 합 분포(이산 합성곱) + 합·숫자 결합 손실

① CNN 블록 (3개, 채널 24→48→96)

$$h^{(l)} = \text{MaxPool}(\text{ReLU}(\text{BN}(W^{(l)} * h^{(l-1)}))), \quad (W * h)(u, v) = \sum_{i,j} W_{ij} h(u+i, v+j)$$

3×3 합성곱 2개 + BN + ReLU + 풀링을 3번 → AdaptiveAvgPool(2×2) → Dropout(0.3) → FC(384→10). 파라미터 총 165,442개

② 숫자 확률

$$p_k = \text{softmax}(z)_k = \frac{e^{z_k}}{\sum_{j=0}^9 e^{z_j}}, \quad z = Wh + b$$

③ 합 분포 (두 숫자는 독립이라고 가정)

$$q(s) = \sum_{a+b=s} p_L(a) p_R(b) = (p_L * p_R)(s), \quad s = 0, \dots, 18, \quad \hat{s} = \arg \max_s q(s)$$

두 확률분포의 합의 분포는 두 분포의 이산 합성곱. 구현은 10×10 곱을 a+b 인덱스로 더하는 index_add

④ 손실

$$\mathcal{L} = -\log q(s^*) + \lambda \text{CE}_\varepsilon(p, c), \quad \lambda = 1$$

$$\text{CE}_\varepsilon(p, c) = -\sum_k [(1 - \varepsilon) \mathbf{1}[k = c] + \frac{\varepsilon}{10}] \log p_k, \quad \varepsilon = 0.05$$

첫 항은 합 라벨만으로 숫자 분류기를 학습시키는 약지도 항, 둘째 항은 숫자 라벨 1,000장 지도 항

⑤ 왜 합만으로 숫자를 배울 수 있나

$$p(a, b | s) = \frac{p_L(a) p_R(b) \mathbf{1}[a+b=s]}{q(s)}$$

합 0-18 은 (0,0)~(9,9)로 숫자가 확정, 합 1 은 {(0,1),(1,0)} 처럼 후보가 좁다. 이런 쌍이 숫자 표현을 붙잡고 같은 모양이 다른 쌍에서도 일관되게 쓰여 나머지도 수렴(EM 과 비슷한 원리)

⑥ 최적화

$$\theta \leftarrow \theta - \eta_t [\hat{m}_t / (\sqrt{\hat{v}_t} + \varepsilon) + \mu \theta] \quad (\text{AdamW}), \quad \eta_t: \text{OneCycle}$$

학습률은 처음 올렸다가 서서히 줄이는 OneCycle 일정, 가중치 감쇠 $\mu=5e-4$, 20 에폭

P3 · Layer-by-layer: CNN, activations, loss

Shared digit classifier applied to left and right 28x28 halves | 165,442 parameters

Layer	Activation	Output	Params
Input		1x28x28	
Conv 3x3, 1→24 (no bias)		24x28x28	216
BatchNorm			48
ReLU			
Conv 3x3, 24→24		24x28x28	5,184
BatchNorm			48
ReLU			
MaxPool 2x2		24x14x14	
Conv 3x3, 24→48		48x14x14	10,368
BatchNorm			96
ReLU			
Conv 3x3, 48→48		48x14x14	20,736
BatchNorm			96
ReLU			
MaxPool 2x2		48x7x7	
Conv 3x3, 48→96		96x7x7	41,472
BatchNorm			192
ReLU			
Conv 3x3, 96→96		96x7x7	82,944
BatchNorm			192
ReLU			
MaxPool 2x2		96x3x3	
AdaptiveAvgPool 2x2		96x2x2	
Flatten + Dropout(0.3)		384	
Linear 384→10		10	3,850
Softmax		10	

Total 165,442 parameters. Each Conv block = [Conv-BN-ReLU] x2 + MaxPool. Same weights for the left and right halves.

Activations

$$\text{ReLU}(x) = \max(0, x)$$

$$\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$$


Loss

$$q(s) = \sum_{a+b=s} p_L(a) p_R(b), \quad s = 0 \dots 18$$

$$\mathcal{L}_{\text{sum}} = -\log q(s^*)$$

$$\mathcal{L}_{\text{digit}} = \text{CE}_{\epsilon=0.05}(p, c)$$

$$\mathcal{L} = \mathcal{L}_{\text{sum}} + \mathcal{L}_{\text{digit}}$$



P3 · 사용된 구성 요소 설명

앞 페이지 표의 각 layer 가 무엇을 하는지 간략 설명

Conv2d 3x3

3x3 필터를 이미지 위로 밀며 국소 패턴(획, 모서리)을 추출.
층이 깊어질수록 더 큰 영역의 조합 패턴(곡선, 숫자 모양)을 봄.

ReLU

$\max(0, x)$. 비선형성을 주면서 기울기 소실이 적고 계산이 간단.

AdaptiveAvgPool + Flatten

특징 맵을 2x2 로 평균 풀링해 입력 크기에 상관없이 고정 길이(384)로 만들.
Flatten 으로 벡터화.

Sum distribution (합성곱)

$q(s) = \sum_{\{a+b=s\}} pL(a) \cdot pR(b)$. 두 숫자 확률분포로부터 합의 분포를 계산.
합 라벨만으로 CNN 에 기울기가 전달되는 약지도 학습의 핵심.

BatchNorm

미니배치 단위로 채널 출력을 정규화(평균 0, 분산 1) 후 학습 가능한 γ, β 적용.
학습이 안정되고 빨라지며 약한 규제 효과.

MaxPool 2x2

2x2 영역의 최대값만 남겨 크기를 절반으로 줄임.
작은 위치 이동에 둔감해지고 계산량이 감소.

Dropout(0.3) + Linear + Softmax

학습 시 30% 를 무작위로 끄고(과적합 방지) 384 $\rightarrow$ 10 선형 변환,
softmax 로 숫자 0~9 의 확률 분포 생성.

Label smoothing + AdamW + OneCycle

정답 확률을 약 0.955 로 낮추고 나머지에 분배(과신 방지).
AdamW(가중치 감쇠 $5e-4$), OneCycle 학습률 일정으로 20 에폭 학습.